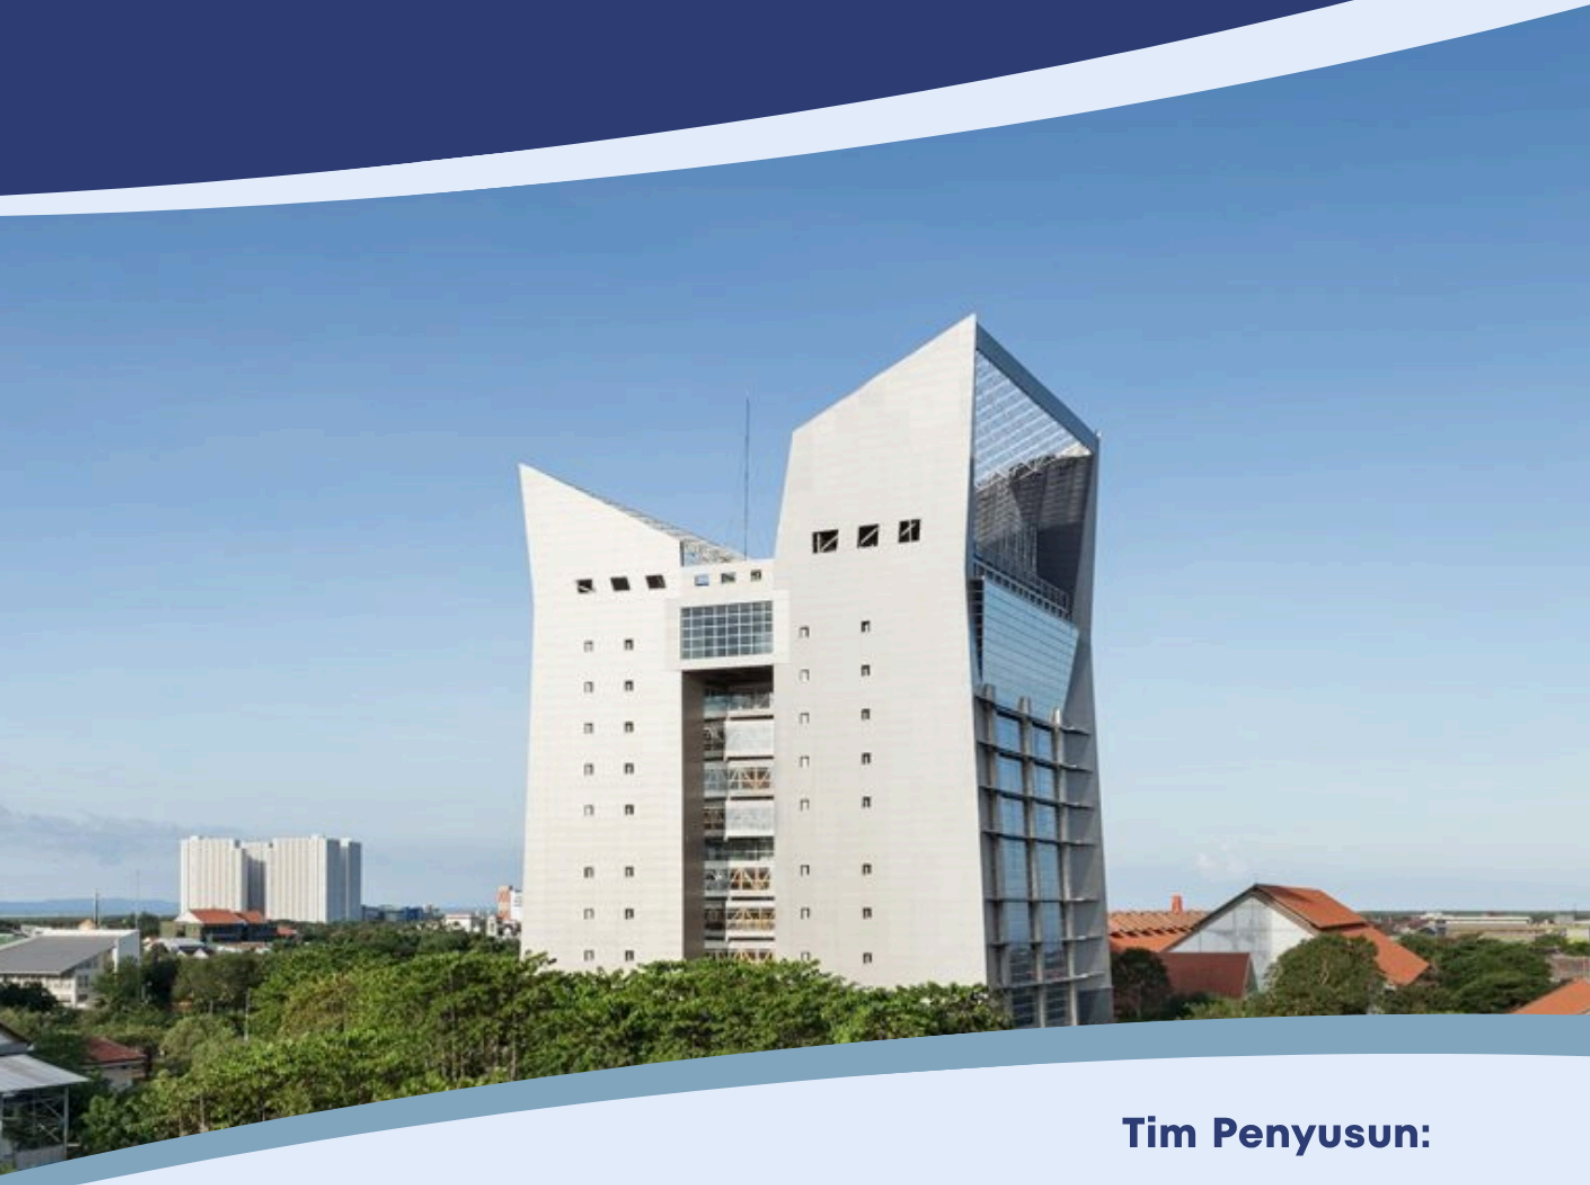
Teknologi Berkembang B

LAPORAN AKHIR

Real-Time Drowsiness Detection Using Convolutional Neural Network (CNN)



Tim Penyusun:

Maria Elvina Putri Damayanti 5026241012
I Gusti Made Sedana Yoga 5026241037
Farhan Fitran Maulana 5026241153
Muhammad Fairuz Ahnaf 5026241169

Departemen Sistem Informasi
Institut Teknologi Sepuluh Nopember

2026

DAFTAR ISI

DAFTAR ISI 1
BAB I
PENDAHULUAN DAN PROBLEM STATEMENT 3
1.1 Latar Belakang 3
1.2 Rumusan Masalah 3
BAB II
TUJUAN DAN RUANG LINGKUP PROYEK 4
2.1 Tujuan Proyek 4
2.2 Ruang Lingkup dan Batasan Masalah 4
BAB III
SOLUSI YANG DIUSULKAN 5
3.1 Gambaran Umum Solusi 5
3.2 Manfaaat Sistem 5
3.3 Gambaran Alur Kerja 5
BAB IV
METODE COMPUTER VISION DAN PENJELASAN TEKNIS 7
4.1 Image Classification dengan CNN 7
4.2 Image Preprocessing 7
4.3 Facial Landmark Detection dengan MediaPipe Face Mesh 8
4.4 Deteksi Mata Real-Time 8
4.5 Pemantauan Durasi Penutupan Mata 8
4.6 Alasan Pemilihan Metode 9
4.7 Arsitektur dan Training EyeCNN 9
BAB V
DATASET DAN PREPROCESSING 11
5.1 Sumber Dataset 11
5.2 Jenis Input dan Kelas Data 11
5.3 Tahap Preprocessing 12
5.4 Pembagian Data 12
BAB VI
DESAIN SISTEM DAN ALUR KERJA 14
6.1 Arsitektur Umum Sistem 14
6.2 Alur Pemantauan dan Keputusan Status 14
6.3 Logika Timer dan Alarm 14
BAB VII
IMPLEMENTASI APLIKASI 16
7.1 Lingkungan, Library, dan Perangkat 16
7.2 Struktur Berkas Aplikasi Akhir 16
7.3 Pemrosesan Frame dan Inferensi 16
7.4 Antarmuka Dashboard Gradio 17
7.5 Audio Alarm dan Reset Monitoring 18
7.6 Perbedaan dengan Prototipe Desktop 18

BAB VIII
SKENARIO PENGUJIAN DAN METODE EVALUASI....19
8.1 Evaluasi Model pada Data Test....19
8.2 Skenario Pengujian Aplikasi....19
8.3 Metrik dan Kriteria Pengujian....20
BAB IX
HASIL DAN PEMBAHASAN....21
9.1 Hasil Training EyeCNN....21
9.2 Hasil Pengujian Model pada Data Test....23
9.3 Pembahasan Hasil Aplikasi....24
BAB X
KETERBATASAN DAN KENDALA....25
10.1 Keterbatasan Dataset dan Generalisasi....25
10.2 Keterbatasan Deteksi dan Logika Peringatan....25
10.3 Kendala Audio dan Browser....26
10.4 Cakupan Pengujian....26
BAB XI
KESIMPULAN DAN RENCANA PENGEMBANGAN....27
11.1 Kesimpulan....27
11.2 Rencana Pengembangan Lanjutan....27
REFERENSI....28
LAMPIRAN....29
Appendix A: Pernyataan Orisinalitas dan Kontribusi....29
Appendix B: GitHub / Version Control Statement....29
Appendix C: Dokumentasi Prototipe Desktop (Tahap Progress)....29
Appendix D: Dokumentasi Prototipe Desktop (Tahap Final)....31

BAB I
PENDAHULUAN DAN PROBLEM STATEMENT

1.1 Latar Belakang

Rasa kantuk adalah hal yang sangat umum dialami, baik saat belajar, bekerja, maupun berkendara. Saat mengantuk, konsentrasi menurun dan seseorang jadi lebih mudah melakukan kesalahan. Pada situasi yang berisiko seperti mengemudi, kehilangan kewaspadaan sesaat saja bisa berujung pada kecelakaan.Salah satu tanda kantuk yang paling mudah diamati adalah kondisi mata, yaitu mata yang tertutup terlalu lama. Tanda ini bisa dipantau lewat kamera biasa menggunakan computer vision, sehingga tidak perlu alat tambahan yang mahal. Dari sinilah proyek ini dibuat, yaitu sistem pendeteksi indikasi kantuk berbasis webcam yang memakai model Convolutional Neural Network (CNN).

Data di Indonesia menunjukkan bahwa masalah ini nyata. Komite Nasional Keselamatan Transportasi (KNKT) memperkirakan sekitar 80% kecelakaan lalu lintas disebabkan oleh kelelahan pengemudi (Brilian, 2023). Contohnya, kecelakaan bus di ruas Tol Semarang-Batang pada 11 April 2024 menewaskan tujuh orang, dan polisi menduga penyebab sementaranya adalah pengemudi yang kelelahan (Bisnis.com, 2024). Kelelahan sering berujung pada rasa kantuk dan hilangnya konsentrasi, dan kantuk sendiri sulit dibuktikan sebagai penyebab setelah kecelakaan terjadi. Walaupun datanya berasal dari bidang berkendara, pola yang sama bisa terjadi pada mahasiswa yang belajar sampai larut malam atau pekerja yang berjaga dalam waktu lama, hanya saja dampaknya biasanya berupa kesalahan kerja dan menurunnya hasil belajar.

Kondisi mata dipilih sebagai indikator karena perubahannya bisa dilihat dari luar tanpa alat khusus. Kedipan normal berlangsung singkat, sekitar 100 sampai 400 milidetik (Soukupová & Čech, 2016), sehingga mata yang tertutup sampai beberapa detik jelas berbeda dari kedipan biasa dan layak dijadikan tanda peringatan.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam proyek ini adalah sebagai berikut.

1. Bagaimana membuat sistem yang dapat mengenali kondisi mata terbuka dan tertutup secara real-time lewat webcam?
2. Bagaimana menghitung durasi mata tertutup dan memberi peringatan ketika durasinya mencapai batas yang ditentukan?
3. Seberapa baik performa model CNN yang dilatih dalam mengenali kondisi mata, baik pada data pengujian maupun saat dicoba langsung dengan webcam?

BAB II
TUJUAN DAN RUANG LINGKUP PROYEK

2.1 Tujuan Proyek

Sejalan dengan rumusan masalah di atas, tujuan proyek ini adalah sebagai berikut:

1. Mengembangkan sistem berbasis computer vision yang dapat mengklasifikasikan kondisi mata terbuka dan tertutup secara real-time lewat webcam menggunakan model CNN hasil training.
2. Menghitung durasi mata tertutup, lalu menampilkan peringatan visual dan membunyikan alarm ketika mata tertutup minimal 2 detik.
3. Mengevaluasi performa model lewat pengujian pada dataset dan pengujian langsung dengan webcam.

2.2 Ruang Lingkup dan Batasan Masalah

Ruang lingkup final mempertahankan dua kelas klasifikasi, yaitu awake (mata terbuka) dan sleepy (mata tertutup), serta memakai penutupan mata berkepanjangan sebagai indikator peringatan. Berbeda dari prototipe desktop pada laporan progress, implementasi akhir memakai antarmuka Gradio yang diakses melalui browser. Webcam dibuka melalui izin browser, frame kemudian dianalisis oleh aplikasi Python yang berjalan secara lokal. Sistem memantau satu wajah, tidak menyimpan rekaman video, dan menggunakan peringatan visual serta audio ketika mata tertutup minimal 2 detik.

Sistem belum memasukkan indikator menguap, gerakan kepala, atau parameter fisiologis lain. Hasil kelas sleepy tidak otomatis berarti seseorang mengantuk, keputusan peringatan diambil dari durasi status mata tertutup. Sistem juga bukan perangkat keselamatan tersertifikasi dan masih bergantung pada visibilitas mata, pencahayaan, serta izin webcam dan audio dari browser.

BAB III
SOLUSI YANG DIUSULKAN

3.1 Gambaran Umum Solusi

Solusi yang dikembangkan adalah pendeteksi indikasi kantuk berbasis webcam. Webcam menangkap wajah pengguna secara terus-menerus, lalu sistem mencari posisi mata pada wajah tersebut. Gambar mata yang sudah ditemukan kemudian diberikan ke model CNN yang bertugas menentukan apakah mata sedang terbuka atau tertutup.

Model CNN ini dilatih terlebih dahulu memakai MRL Eye Dataset (Fusek, 2018), yaitu dataset gambar mata terbuka dan mata tertutup berupa citra inframerah yang diambil dari banyak orang dalam berbagai kondisi pencahayaan. Setelah selesai dilatih, model dihubungkan dengan webcam supaya bisa memprediksi secara real-time. Sistem lalu menghitung berapa lama mata terdeteksi tertutup. Kalau durasinya mencapai minimal 2 detik, sistem menampilkan peringatan visual di layar dan membunyikan alarm. Begitu mata terbuka lagi, hitungan durasi diulang dari awal, sehingga kedipan biasa tidak memicu alarm.

Dalam implementasi akhir, sistem tersedia sebagai aplikasi Gradio yang dijalankan secara lokal dan dibuka melalui browser. Dashboard menampilkan Live Webcam, Eye Status, Eye Closure Duration, Alarm Status, serta Eye Preview. Gambar mata yang digunakan CNN juga dapat dilihat pada jendela pratinjau terpisah. Ketika mata tertutup cukup lama, dashboard menampilkan peringatan dan komponen audio browser memutar alarm.mp3 secara berulang, selama izin pemutaran audio mengizinkan.

3.2 Manfaaat Sistem

Manfaat utama sistem ini adalah memberi peringatan dini kepada pengguna yang mulai kehilangan kewaspadaan, sehingga pengguna bisa segera sadar dan mengambil tindakan, misalnya istirahat atau berhenti sejenak. Sistem ini bisa dipakai oleh mahasiswa yang belajar lama di depan laptop, pekerja yang bertugas dalam waktu panjang, maupun sebagai gambaran awal untuk sistem keselamatan pengemudi.

Dari sisi teknis, sistem ini hanya membutuhkan webcam biasa dan komputer, jadi mudah dicoba tanpa perangkat khusus. Proyek ini juga menjadi contoh penerapan computer vision yang menggabungkan beberapa teknik sekaligus, mulai dari preprocessing, deteksi landmark wajah, sampai klasifikasi dengan CNN.

3.3 Gambaran Alur Kerja

Secara garis besar, sistem bekerja dalam lima tahap yang berulang untuk setiap frame dari webcam. Pertama, webcam mengirim frame ke program. Kedua, MediaPipe Face Mesh mencari wajah dan menentukan posisi mata. Ketiga, area kedua mata dipotong lalu diproses dengan transformasi dari library torchvision agar ukuran dan nilai pikselnya sesuai kebutuhan CNN. Keempat, CNN memprediksi apakah mata terbuka atau tertutup, dan hasilnya dihaluskan agar tidak berubah-ubah. Kelima, sistem memperbarui timer: jika mata tertutup, timer berjalan, dan jika mata

terbuka, timer diulang dari nol. Saat timer mencapai 2 detik, peringatan visual dan alarm diaktifkan.

BAB IV
METODE COMPUTER VISION DAN PENJELASAN TEKNIS

4.1 Image Classification dengan CNN

Inti dari sistem ini adalah image classification, yaitu tugas mengelompokkan sebuah gambar ke dalam kelas tertentu. Dalam proyek ini ada dua kelas, yaitu mata terbuka (open, bernama awake di dataset) dan mata tertutup (closed, bernama sleepy di dataset). Untuk tugas ini dipakai Convolutional Neural Network (CNN), yaitu jenis jaringan saraf tiruan yang memang dirancang untuk memproses gambar.

Cara kerjanya secara sederhana, CNN menyaring gambar lewat beberapa lapisan untuk menangkap ciri-ciri penting, mulai dari garis dan tepi sampai bentuk yang lebih rumit seperti kelopak mata dan area pupil. Dari ciri-ciri itu, lapisan terakhir memutuskan gambar tersebut termasuk kelas awake atau sleepy.

Secara umum, CNN tersusun dari beberapa jenis lapisan. Lapisan konvolusi bertugas menemukan pola lokal pada gambar, seperti tepi dan lengkung kelopak mata, menggunakan filter kecil yang digeser di seluruh gambar. Lapisan pooling memperkecil ukuran hasil konvolusi sehingga perhitungan lebih ringan dan model tidak terlalu peka terhadap pergeseran kecil. Setelah itu, lapisan fully connected menggabungkan semua ciri yang sudah ditemukan, dan fungsi softmax mengubah keluarannya menjadi nilai kemungkinan untuk setiap kelas. Kelas dengan nilai tertinggi menjadi hasil prediksi (LeCun et al., 1998; LeCun et al., 2015).

CNN tidak diprogram dengan aturan, melainkan dilatih. Model diberi banyak gambar mata yang sudah diberi label open atau closed, lalu bobotnya disesuaikan sedikit demi sedikit sampai kesalahan prediksinya kecil. Model dibuat dan dilatih menggunakan PyTorch (Paszke et al., 2019). Karena tugasnya hanya membedakan dua kelas dari gambar yang kecil, dipakai CNN yang ringan, yaitu tiga lapisan konvolusi diikuti lapisan klasifikasi.

4.2 Image Preprocessing

Sebelum masuk ke CNN, gambar mata perlu disiapkan dulu agar bentuknya seragam. Untuk itu dilakukan tiga langkah utama. Pertama, konversi ke grayscale, supaya model fokus pada bentuk mata dan bukan pada warna, sekaligus membuat proses lebih ringan. Kedua, resizing, yaitu mengubah semua gambar ke ukuran yang sama, yaitu 64×64 piksel, karena CNN membutuhkan input dengan ukuran tetap. Ketiga, normalisasi, yaitu mengubah nilai piksel ke rentang yang kecil (dalam proyek ini antara -1 dan 1) supaya proses training lebih stabil. Ketiganya dijalankan dengan transformasi dari library torchvision, baik pada tahap training maupun pada sistem webcam, sehingga gambar mata yang masuk ke CNN selalu diproses dengan cara yang sama.

Setiap langkah preprocessing punya alasan. Grayscale cukup untuk membedakan mata terbuka dan tertutup karena yang penting adalah bentuk dan gelap terangnya, bukan warna kulit atau warna iris, dan ini juga mengurangi data dari tiga kanal warna menjadi satu. Ukuran gambar harus sama karena jumlah neuron di lapisan awal CNN ditetapkan di depan. Normalisasi membuat nilai masukan berada pada skala kecil sehingga proses training lebih stabil. Yang tidak

kalah penting, langkah preprocessing yang sama harus dipakai saat training dan saat prediksi lewat webcam, karena kalau berbeda, model akan menerima gambar yang tidak sesuai dengan yang dipelajarinya.

Pada aplikasi Gradio, webcam browser menghasilkan frame RGB. OpenCV digunakan untuk membalik frame secara horizontal dan menyesuaikan ukuran sebelum diteruskan ke MediaPipe. Area mata yang sudah dipotong dikonversi menjadi gambar PIL dan diproses menggunakan transformasi torchvision yang sama seperti saat training.

4.3 Facial Landmark Detection dengan MediaPipe Face Mesh

Agar CNN hanya menerima gambar mata, sistem perlu tahu dulu di mana letak mata pada wajah. Untuk itu dipakai MediaPipe Face Mesh, yaitu library yang bisa menemukan ratusan titik penting pada wajah secara real-time. Dari titik-titik di sekitar mata, sistem memotong area mata dari frame webcam, lalu area itulah yang dikirim ke tahap preprocessing dan CNN. Perlu dicatat bahwa MediaPipe di sini hanya berperan sebagai penunjuk lokasi mata. Keputusan apakah mata terbuka atau tertutup tetap dibuat oleh model CNN.

Face Mesh menghasilkan 468 titik tiga dimensi yang menggambarkan permukaan wajah dari satu kamera biasa, dan modelnya dirancang cukup ringan untuk berjalan secara real-time (Kartynnik et al., 2019). Face Mesh sendiri dibangun di atas MediaPipe, yaitu kerangka kerja untuk menyusun alur pemrosesan data persepsi seperti video (Lugaresi et al., 2019). Dalam proyek ini, enam titik landmark pada setiap mata (dua di sudut mata dan empat di kelopak atas dan bawah) dipakai untuk menentukan kotak pemotongan. Kotak tersebut berpusat di tengah mata, dengan lebar 1,55 kali dan tinggi 0,90 kali lebar mata, supaya seluruh kelopak ikut masuk ke gambar yang dikirim ke CNN. Potongan diambil dari kedua mata, dan keduanya diprediksi bersamaan. Karena posisinya mengikuti titik wajah pada setiap frame, potongan mata tetap pas walaupun pengguna menggerakkan kepala. Sistem hanya memantau satu wajah dalam satu waktu.

4.4 Deteksi Mata Real-Time

Untuk mendukung pemantauan real-time, Gradio menerima frame webcam browser dalam format RGB dan mengirimkannya ke fungsi analisis Python. OpenCV membalik serta menyesuaikan ukuran frame, MediaPipe Face Mesh menentukan lokasi mata, dan EyeCNN mengklasifikasikan kedua potongan mata. Hasilnya diperbarui pada dashboard berupa status mata, skor penutupan, preview, serta durasi. Lebar frame dibatasi hingga 640 piksel jika lebih besar untuk menjaga efisiensi pemrosesan. CNN hanya memproses crop mata 64×64 piksel; aplikasi memakai CUDA jika tersedia atau CPU sebagai alternatif.

4.5 Pemantauan Durasi Penutupan Mata

Hasil prediksi CNN pada satu frame saja belum cukup untuk menyimpulkan kantuk, karena orang normal juga berkedip. Karena itu sistem menghitung durasi mata tertutup. Ketika prediksi berubah menjadi closed, timer mulai berjalan. Kalau prediksi kembali open, timer di-reset. Alarm baru aktif ketika mata tertutup

terus-menerus selama minimal 2 detik, sehingga kedipan singkat tidak dianggap sebagai kantuk.

Batas 2 detik ditentukan dengan mempertimbangkan lamanya kedipan normal. Satu kedipan berlangsung sekitar 100 sampai 400 milidetik (Soukupová & Čech, 2016), jadi jauh lebih singkat dari 2 detik. Dengan batas ini, kedipan biasa tidak membunyikan alarm, sedangkan mata yang tertutup terus-menerus cukup lama sudah dianggap sebagai tanda bahaya. Durasi dihitung dari selisih waktu sejak mata pertama kali terdeteksi tertutup, sehingga hasilnya tidak bergantung pada seberapa cepat komputer memproses frame.

Logika ini bisa dipandang sebagai mesin keadaan sederhana dengan dua keadaan. Pada keadaan mata terbuka, timer bernilai nol dan tidak ada peringatan. Ketika prediksi berubah menjadi closed, sistem masuk ke keadaan mata tertutup dan mencatat waktu mulainya. Kalau prediksi kembali open sebelum 2 detik, sistem kembali ke keadaan awal. Kalau durasi mencapai 2 detik, peringatan visual dan alarm diaktifkan.

Agar status tidak berubah-ubah akibat gangguan pada satu frame, skor kelas sleepy dari kedua mata dirata-rata, lalu dihaluskan dengan rata-rata bergerak (bobot 0,25 untuk skor baru). Perubahan keadaan memakai dua ambang: dari mata terbuka ke tertutup saat smoothed prediction score mencapai 0,60 atau lebih, dan kembali ke terbuka saat skor turun ke 0,40 atau kurang. Jika wajah atau salah satu mata tidak terdeteksi, timer dan skor direset serta alarm dihentikan.

4.6 Alasan Pemilihan Metode

CNN dipilih karena model ini belajar langsung dari gambar, jadi bisa mengenali ciri mata terbuka dan tertutup tanpa perlu aturan manual. Dibandingkan pendekatan berbasis rumus jarak antar titik landmark seperti Eye Aspect Ratio (EAR), CNN lebih fleksibel karena melihat tampilan mata secara utuh. Pendekatan ini juga lebih cocok untuk tugas computer vision berbasis gambar yang sedang dipelajari di mata kuliah ini.

MediaPipe Face Mesh dipilih karena ringan dan bisa menentukan lokasi mata pada video real-time. OpenCV menangani pengolahan frame, sedangkan Gradio menyediakan komponen webcam, dashboard dan pemutaran alarm melalui browser. Timer 2 detik ditetapkan sebagai ambang peringatan awal agar kedipan normal yang singkat tidak langsung dianggap sebagai kondisi berbahaya.

4.7 Arsitektur dan Training EyeCNN

Model yang dipakai bernama EyeCNN. Masukannya adalah gambar mata berukuran 1×64×64. Bagian pertama model terdiri atas tiga blok konvolusi. Tiap blok berisi lapisan Conv2d dengan kernel 3×3 dan padding 1, fungsi aktivasi ReLU, lalu MaxPool2d 2×2. Jumlah filter pada blok pertama, kedua, dan ketiga adalah 16, 32, dan 64. Setiap max pooling mengecilkan ukuran peta ciri menjadi setengahnya, yaitu dari 64×64 menjadi 32×32, lalu 16×16, dan 8×8. Setelah itu, AdaptiveAvgPool2d mengubah ukurannya menjadi 4×4, sehingga keluaran bagian ini berukuran 64×4×4, atau 1.024 nilai setelah diratakan dengan Flatten.

Bagian kedua adalah classifier. Lapisan Linear mengubah 1.024 nilai menjadi 64, diikuti ReLU dan Dropout sebesar 0,3. Dropout mematikan sebagian neuron secara acak saat training, supaya model tidak terlalu menghafal data latih. Lapisan

Linear terakhir menghasilkan dua skor, satu untuk awake dan satu untuk sleepy. Jika dihitung dari susunan lapisannya, model ini memiliki 89.026 parameter, sehingga tergolong kecil dan ringan.

Training memakai CrossEntropyLoss sebagai fungsi loss dan optimizer Adam dengan learning rate 0,001. Batch size yang dipakai 32 dan jumlah epoch 15. Data training diacak (shuffle) di setiap epoch, sedangkan data validation tidak. Seed diatur ke 42 pada PyTorch supaya hasil lebih mudah diulang.

Pada setiap epoch, model dilatih dengan data training dalam mode training (Dropout aktif), kemudian dinilai pada data validation dalam mode evaluasi tanpa mengubah bobot. Loss dan accuracy dicatat untuk setiap epoch untuk membuat grafik training. Jika validation loss pada suatu epoch lebih kecil daripada yang terbaik sebelumnya, bobot saat itu disimpan ke eye_cnn_best.pth. File tersebut berisi bobot model, nama kelas, dan ukuran gambar, supaya program webcam memakai ukuran dan urutan kelas yang sama dengan saat training. Pada training ini, bobot terbaik berasal dari epoch ke-8, karena validation loss pada epoch-epoch berikutnya tidak lebih kecil daripada nilai tersebut. Setelah training, bobot terbaik dimuat lagi, lalu dievaluasi pada data test dengan classification report (accuracy, precision, recall, dan F1-score) dan confusion matrix. Hasil angkanya dibahas pada Bab IX.

BAB V
DATASET DAN PREPROCESSING

5.1 Sumber Dataset

Dataset yang dipakai adalah MRL Eye Dataset yang disusun oleh Fusek (2018). Dataset ini berisi gambar mata manusia berupa citra inframerah dengan resolusi rendah dan tinggi. Gambarnya diambil pada berbagai kondisi pencahayaan dan dengan perangkat yang berbeda. Menurut situs resminya, ada tiga jenis sensor yang dipakai, yaitu Intel RealSense, IDS Imaging, dan Aptina. Jumlah seluruh gambarnya 84.898, terdiri atas 41.945 gambar mata tertutup dan 42.953 gambar mata terbuka (Fusek, 2018), sehingga jumlah kedua kelas hampir seimbang.

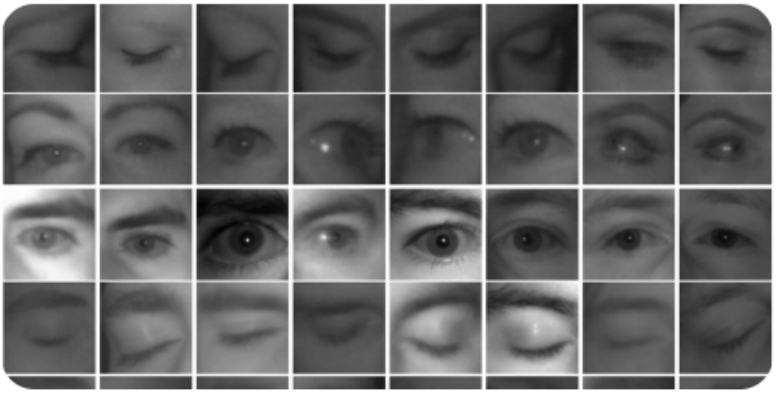
Dataset ini dipilih karena jumlahnya besar, sudah diberi label kondisi mata, dan memuat variasi pencahayaan serta perangkat, sehingga cocok untuk melatih CNN yang membedakan dua kelas. Pada proyek ini, dataset diunduh dari Kaggle (akashshingha850, n.d.), yaitu versi turunan (forked version) dari MRL Eye Dataset yang sudah dibagi menjadi folder train, val, dan test, dengan dua folder kelas di dalamnya, yaitu awake untuk mata terbuka dan sleepy untuk mata tertutup. Menurut keterangan di halaman tersebut, gambar berasal dari 37 subjek dan dilengkapi metadata berupa ID subjek, kondisi mata, jenis kelamin, pemakaian kacamata, pantulan cahaya, kondisi pencahayaan, dan ID sensor. Pada versi ini jumlah gambarnya 42.952 mata terbuka dan 41.946 mata tertutup, berbeda satu gambar dari angka pada paper aslinya, dengan jumlah total yang sama.

5.2 Jenis Input dan Kelas Data

Input model berupa gambar mata, bukan gambar wajah utuh. Gambar dibaca dengan ImageFolder dari library torchvision, yang memakai nama folder sebagai label kelas. Informasi tambahan tentang setiap gambar tersimpan pada nama filenya, misalnya s0001_01846_0_0_1_0_0_01.png, yang diawali kode subjek.

Ada dua kelas, yaitu awake untuk mata terbuka dan sleepy untuk mata tertutup, yang di laporan ini disebut open dan closed. ImageFolder memberi nomor kelas berdasarkan urutan abjad nama folder, sehingga awake bernilai 0 dan sleepy bernilai 1. Kode juga memeriksa bahwa nama kelas harus tepat awake dan sleepy, dan harus sama pada folder train, val, dan test. Jika tidak sama, program berhenti dengan pesan kesalahan.

Seperti pada batasan masalah, kelas sleepy hanya berarti mata tertutup pada gambar tersebut. Kelas ini bukan penilaian bahwa seseorang pasti mengantuk. Keputusan kantuk baru diambil setelah durasi mata tertutup dihitung oleh timer.

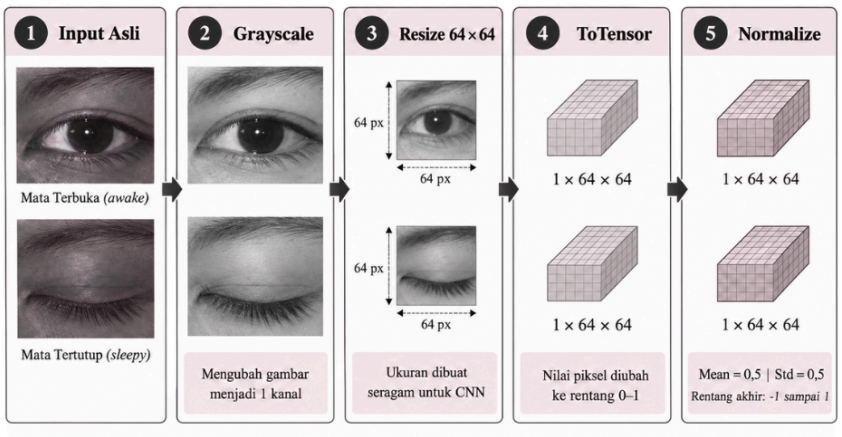


Gambar 5.1 Contoh potongan mata terbuka dan tertutup pada dataset

5.3 Tahap Preprocessing

Semua gambar melalui empat tahap preprocessing menggunakan torchvision. Pertama, Grayscale mengubah gambar menjadi satu kanal warna agar sesuai dengan input CNN dan lebih berfokus pada bentuk mata. Kedua, Resize menyeragamkan ukuran gambar menjadi 64×64 piksel agar proses training dan prediksi lebih ringan. Ketiga, ToTensor mengubah gambar menjadi tensor berukuran 1×64×64 dengan nilai piksel antara 0 dan 1. Terakhir, Normalize menggunakan mean 0,5 dan standar deviasi 0,5 untuk mengubah rentang nilai menjadi -1 hingga 1, sehingga proses pembelajaran model lebih stabil.

Transformasi yang sama diterapkan pada data training, validation, dan testing. Notebook belum menggunakan data augmentation, sehingga gambar tidak mengalami modifikasi tambahan selama training. Ukuran input dan nama kelas disimpan dalam checkpoint model agar dapat digunakan kembali saat prediksi. Pada aplikasi final, frame dari Gradio sudah berformat RGB. Area mata yang dipotong dari frame tersebut diproses menggunakan PIL dan torchvision dengan transformasi yang sama seperti saat training.



Gambar 5.2 Tahap preprocessing pada dataset

5.4 Pembagian Data

Dataset dibagi menjadi tiga bagian dengan fungsi berbeda. Data training dipakai untuk melatih model, yaitu menyesuaikan bobot CNN. Data validation

dipakai di akhir setiap epoch untuk memantau performa pada gambar yang tidak dipakai melatih, dan hasilnya menentukan bobot mana yang disimpan sebagai model terbaik. Data test tidak dipakai selama training maupun pemilihan model, dan baru dipakai setelah training selesai untuk menilai performa akhir.

Jumlah gambar tiap bagian, menurut output notebook, adalah 50.937 gambar untuk training, 16.980 untuk validation, dan 16.981 untuk testing. Totalnya 84.898 gambar, sama dengan jumlah dataset asli, dengan perbandingan sekitar 60%, 20%, dan 20%. Rincian per kelas ditunjukkan pada Tabel 5.1.

Tabel 5.1 Jumlah gambar per bagian dan per kelas

Bagian	Awake (open)	Sleepy (closed)	Total
Train	25.770	25.167	50.937
Validation	8.591	8.389	16.980
Test	8.591	8.390	16.981

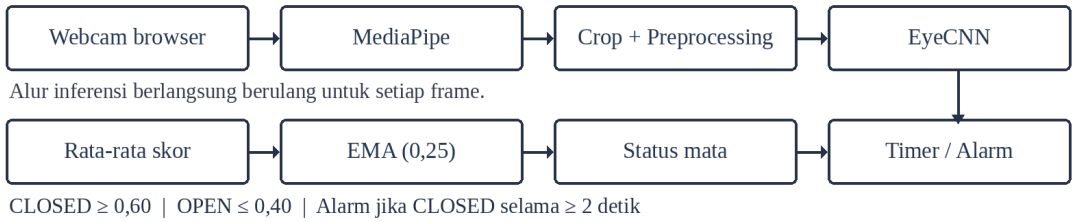
Pembagian data menjadi training, validation, dan testing sudah disediakan oleh pengunggah dataset di Kaggle. Ketiga bagian memiliki proporsi sekitar 60%, 20%, dan 20%, dengan jumlah gambar mata terbuka dan tertutup yang relatif seimbang. Namun, metode pembagian data belum dijelaskan secara rinci, sehingga masih terdapat kemungkinan kemiripan data antarbagian. Oleh karena itu, hasil pada data test sebaiknya dibaca sebagai gambaran awal, dan pengujian langsung dengan webcam pada bab evaluasi diperlukan untuk menilai performa model pada orang yang benar-benar baru.

BAB VI
DESAIN SISTEM DAN ALUR KERJA

6.1 Arsitektur Umum Sistem

Arsitektur sistem terdiri atas dua proses yang terpisah: training model di notebook dan inferensi aplikasi real-time. Training memanfaatkan MRL Eye Dataset untuk menghasilkan checkpoint eye_cnn_best.pth. Ketika aplikasi dijalankan, model dan metadata kelas dimuat satu kali dalam mode evaluasi. Selanjutnya, frame webcam dari Gradio diproses menggunakan MediaPipe Face Mesh, cropping mata, transformasi torchvision, dan EyeCNN.

Masing-masing mata menghasilkan skor kelas sleepy. Kedua skor dirata-rata dan dihaluskan dengan Exponential Moving Average (EMA). Skor akhir kemudian menentukan status mata melalui dua ambang, sedangkan durasi penutupan dihitung menggunakan time.monotonic(). Saat durasi mencapai dua detik, dashboard menampilkan Drowsiness Warning dan memutar alarm. Proses ini berulang selama streaming aktif.



Gambar 6.1 Alur inferensi webcam dan pengambilan keputusan pada aplikasi Gradio.

6.2 Alur Pemantauan dan Keputusan Status

Tabel 6.1 Alur pemrosesan frame pada dasbor Gradio beserta keluaran tiap tahap

Tahap	Proses	Keluaran
1	Webcam browser (Gradio)	Frame RGB dari kamera
2	MediaPipe Face Mesh	Landmark mata kiri dan kanan
3	Crop + preprocessing	Tensor grayscale 1 x 64 x 64
4	EyeCNN (PyTorch)	Skor sleepy kedua mata
5	Rata-rata + EMA (alpha 0,25)	Skor prediksi lebih stabil
6	Threshold status	CLOSED >= 0,60; OPEN <= 0,40
7	Timer dan alarm	Peringatan setelah CLOSED >= 2 detik

Dua ambang tersebut membentuk histeresis: ketika skor berada di antara 0,40 dan 0,60, status OPEN/CLOSED sebelumnya dipertahankan. Jika wajah atau area mata tidak terdeteksi, status ditandai FACE NOT FOUND dan timer serta alarm direset. Desain ini mengurangi alarm akibat kedipan singkat, tetapi belum mengatasi seluruh variasi gerak wajah atau kondisi cahaya.

6.3 Logika Timer dan Alarm

Seperti dijelaskan pada subbab 4.5, prediksi satu frame saja tidak cukup untuk menentukan kantuk karena orang normal juga berkedip. Karena itu, sistem menghitung durasi mata tertutup berdasarkan selisih waktu, bukan jumlah frame,

memakai fungsi time.monotonic. Status awal adalah OPEN. Status berubah menjadi CLOSED saat smoothed prediction score mencapai 0,60 atau lebih, dan waktu saat itu dicatat sebagai waktu mulai. Status kembali OPEN saat smoothed prediction score turun ke 0,40 atau kurang, dan waktu mulai dikosongkan. Dua ambang ini mencegah status berubah-ubah ketika skor berada di sekitar batas. Selama status CLOSED, durasi dihitung dari selisih waktu sekarang dengan waktu mulai. Jika durasi mencapai 2 detik, peringatan visual muncul dan alarm.mp3 diputar berulang melalui komponen audio browser. Batas 2 detik jauh di atas lama kedipan normal sekitar 100 sampai 400 milidetik, sehingga kedipan biasa tidak membunyikan alarm.

BAB VII
IMPLEMENTASI APLIKASI

7.1 Lingkungan, Library, dan Perangkat

Proyek ini memakai bahasa Python versi 3.11. Model CNN dibuat dan dilatih dengan PyTorch. Library torchvision dipakai untuk membaca dataset dari folder dengan ImageFolder dan untuk transformasi gambar. Library scikit-learn dipakai untuk membuat classification report dan confusion matrix pada data test. Grafik loss dan accuracy serta tampilan confusion matrix dibuat dengan Matplotlib. Library Pillow dipakai untuk membuka gambar dan untuk mengubah potongan mata menjadi gambar PIL sebelum ditransformasi.

Pada aplikasi final, Gradio menerima frame webcam langsung dari browser, MediaPipe Face Mesh menentukan landmark mata, OpenCV membantu pembalikan dan crop frame, sedangkan PyTorch melakukan inferensi EyeCNN. Berkas alarm.mp3 diputar melalui komponen gr.Audio (autoplay dan loop) pada browser. NumPy membantu pengolahan array gambar, sedangkan modul time milik Python menghitung durasi penutupan mata.

Versi library yang dipakai tercatat pada berkas requirements.txt sedangkan nomor versi lengkap dari environment lokal belum diverifikasi untuk laporan ini. Training dijalankan menggunakan PyTorch dengan GPU CUDA jika tersedia, atau CPU sebagai alternatif. Berdasarkan output notebook yang dicatat pada laporan awal, training menggunakan NVIDIA GeForce RTX 5060 Laptop. Aplikasi Gradio memilih CUDA jika tersedia atau CPU sebagai alternatif.

7.2 Struktur Berkas Aplikasi Akhir

Implementasi akhir memakai Source_Code/main.py sebagai entry point. File Source_Code/eye_cnn_best.pth memuat bobot model hasil training; Source_Code/style.css mengatur tata letak dan tampilan dashboard; Source_Code/alarm.mp3 menjadi sumber suara peringatan. Notebook Source_Code/train_eye_cnn.ipynb dipakai untuk training dan evaluasi, sedangkan Source_Code/predict_eye_webcam_custom_alarm.py tetap tersimpan sebagai prototipe desktop sebelumnya. Berkas requirements.txt mendokumentasikan dependensi program.

7.3 Pemrosesan Frame dan Inferensi

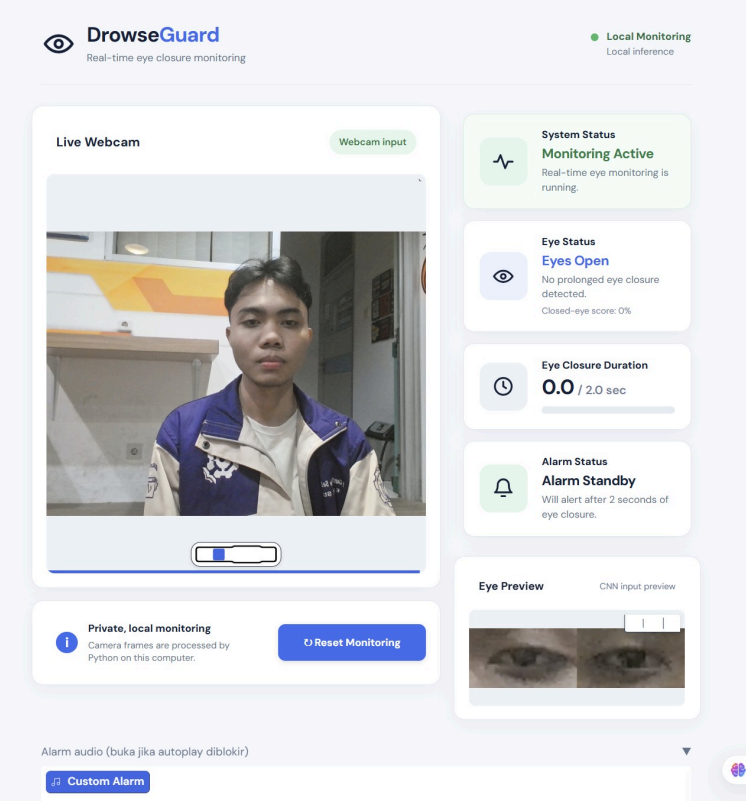
Aplikasi dijalankan dengan python Source_Code/main.py. Saat startup, main.py menentukan lokasi berkas berdasarkan Path(__file__).resolve().parent, memeriksa keberadaan checkpoint dan alarm, memuat model EyeCNN, lalu menyiapkan MediaPipe Face Mesh dan preprocessing yang konsisten dengan notebook training.

Di Gradio, komponen gr.Image menerima gambar dari webcam secara streaming sebagai array NumPy RGB. Fungsi analyze_frame memproses frame secara berulang: membalik secara horizontal sebagai tampilan cermin, membatasi lebar gambar jika lebih dari 640 piksel, mencari landmark kedua mata, lalu melakukan crop dan preprocessing. Kedua tensor mata diproses bersama melalui

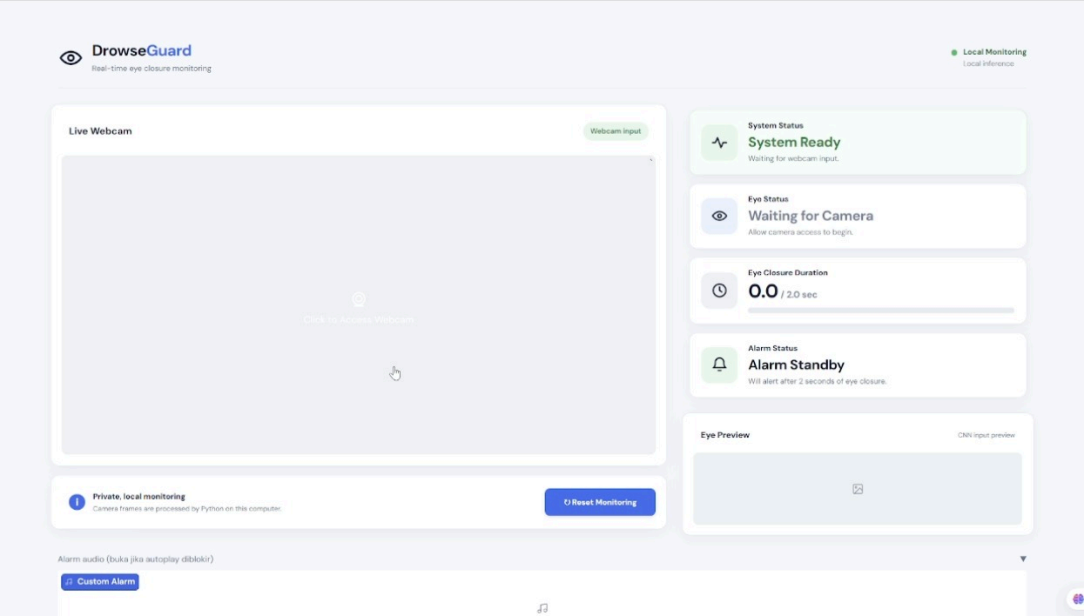
PyTorch. Skor kelas sleepy dirata-rata, dihaluskan, dan diterjemahkan menjadi status OPEN atau CLOSED. Jika frame kosong atau wajah tidak ditemukan, status dan timer diperbarui sesuai logika reset.

7.4 Antarmuka Dashboard Gradio

Dashboard Gradio terdiri atas panel Live Webcam, System Status, Eye Status, Eye Closure Duration, Alarm Status, Eye Preview, dan tombol Reset Monitoring. Tampilan disusun menggunakan gr.Blocks dan CSS terpisah agar pemantauan lebih mudah dibaca daripada jendela desktop prototipe. Panel status menampilkan kondisi mata dan skor penutupan, panel durasi menunjukkan progres menuju ambang 2 detik, sedangkan Eye Preview memperlihatkan potongan mata yang menjadi masukan model.



Gambar 7.1 Tangkapan layar pengujian streaming Gradio pada tahap pengembangan antarmuka.



Gambar 7.2 Tangkapan layar halaman Gradio sebelum webcam diaktifkan pada iterasi desain awal.

Keterangan: kedua tangkapan layar di atas berasal dari iterasi antarmuka Gradio yang pernah diuji selama pengembangan, sehingga belum menggambarkan tampilan versi akhir aplikasi. Tangkapan layar versi final perlu ditambahkan untuk menggantikannya.

7.5 Audio Alarm dan Reset Monitoring

Jika status mata tetap CLOSED minimal 2 detik, aplikasi menandai Alarm Active dan mengirim path alarm.mp3 ke komponen gr.Audio. Pemain audio diatur autoplay=True dan loop=True agar suara berulang selama kondisi alarm aktif. Ketika mata kembali OPEN, wajah hilang, atau pengguna menekan Reset Monitoring, audio dihentikan dan timer direset. Browser dapat memblokir autoplay sebelum interaksi pengguna; karena itu aplikasi menyediakan bagian pengaturan audio yang dapat dibuka untuk memutar alarm secara manual.

7.6 Perbedaan dengan Prototipe Desktop

Pada laporan progress, input kamera dibaca langsung oleh OpenCV dan hasilnya muncul pada jendela desktop, sementara suara alarm dikelola Pygame. Pada implementasi final, pengambilan input dan visualisasi berpindah ke Gradio di browser. Model CNN, transformasi preprocessing, MediaPipe, skor prediksi, smoothing, threshold, serta logika durasi 2 detik tetap mengikuti rancangan yang sama. Dengan demikian, pengembangan final berfokus pada pengalaman penggunaan dan integrasi interface, bukan pelatihan ulang model.

BAB VIII
SKENARIO PENGUJIAN DAN METODE EVALUASI

8.1 Evaluasi Model pada Data Test

Evaluasi dilakukan dalam dua jenis pengujian yang saling melengkapi. Pengujian pertama memakai data test dari dataset sebanyak 16.981 gambar yang tidak dipakai selama training maupun pemilihan model. Pada pengujian ini, model dinilai dengan accuracy, precision, recall, F1-score, dan confusion matrix. Pengujian ini mengukur kemampuan CNN membedakan mata terbuka dan tertutup pada gambar dari dataset.

8.2 Skenario Pengujian Aplikasi

Pengujian fungsi aplikasi dilakukan pada prototipe desktop menggunakan webcam bawaan laptop oleh anggota kelompok. Setelah antarmuka bermigrasi ke Gradio, skenario yang sama relevan untuk pengujian ulang. Pengujian desktop awal dilakukan secara kualitatif melalui pengamatan status dan suara alarm, bukan menggunakan pengukuran akurasi webcam secara kuantitatif. Catatan awal menyebutkan peringatan muncul ketika mata ditutup sekitar 2 detik, sistem masih dapat berjalan dengan kacamata bening, dan tidak dapat bekerja baik saat memakai kacamata hitam. Jumlah peserta, tipe perangkat, jumlah percobaan, dan hasil kondisi lain belum terdokumentasi lengkap sehingga perlu dicatat pada pengujian berikutnya.

Data uji lapangan yang masih perlu dilengkapi meliputi jumlah peserta, spesifikasi perangkat, kondisi pencahayaan, jumlah percobaan per skenario, serta apakah alarm tepat berbunyi dan berhenti pada tiap percobaan.

Tabel 8.1 Hasil pengujian dengan webcam

Skenario	Program dan jenis bukti	Hasil yang tercatat
Mata tertutup sekitar 2 detik	OpenCV (desktop; pengujian awal)	Peringatan visual muncul dan alarm berbunyi
Kacamata bening	OpenCV (desktop; pengujian awal)	Mata tetap terdeteksi dan alarm berfungsi
Kacamata hitam	OpenCV (desktop; pengujian awal)	Mata tidak terlihat sehingga deteksi gagal
Kedipan biasa	OpenCV (desktop; observasi awal)	Alarm tidak aktif karena durasi kurang dari 2 detik
Pencahayaan redup	OpenCV (desktop; observasi awal)	Deteksi mata menjadi kurang stabil
Wajah keluar dari frame	OpenCV (desktop; logika sistem)	Status tidak ditemukan; timer dan alarm direset

8.3 Metrik dan Kriteria Pengujian

Evaluasi model pada 16.981 gambar test menggunakan accuracy, precision, recall, F1-score, dan confusion matrix. Pengujian aplikasi meliputi kondisi mata terbuka, berkedip, tertutup minimal 2 detik, kacamata, pencahayaan redup, dan wajah keluar dari frame (Tabel 8.1). Output yang diamati adalah status, timer, peringatan visual, dan alarm. Pengujian webcam masih kualitatif sehingga belum tersedia angka akurasi end-to-end dan latency untuk Gradio final.

BAB IX
HASIL DAN PEMBAHASAN

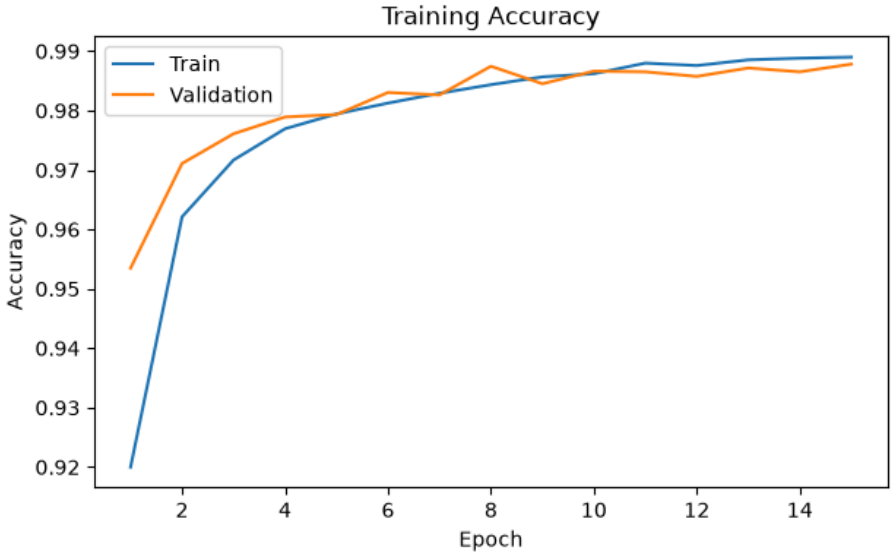
9.1 Hasil Training EyeCNN

Training dijalankan selama 15 epoch dengan batch size 32. Tabel 9.1 menunjukkan hasil pada 15 epoch terpilih. Pada epoch pertama, accuracy training 92,00% dan accuracy validation 95,35%. Accuracy validation lebih tinggi daripada accuracy training pada epoch ini karena accuracy training dihitung rata-rata selama epoch berjalan, saat bobot model masih berubah dan Dropout aktif, sedangkan validation dinilai setelah epoch selesai dengan Dropout dimatikan. Validation loss turun dari 0,1310 pada epoch pertama menjadi 0,0373 pada epoch ke-8, lalu bergerak di kisaran 0,0379 sampai 0,0416 pada epoch ke-9 sampai ke-15. Accuracy validation naik sampai 98,78% pada epoch ke-15.

Tabel 9.1 Hasil training pada epoch 15 terpilih

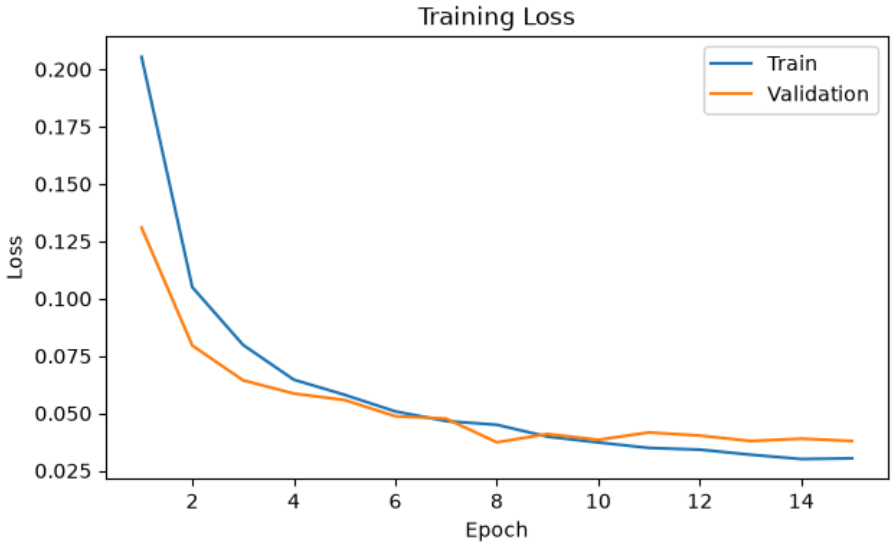
Epoch	Accuracy Training	Accuracy Validation	Validation Loss
1	92,00%	95,35%	0,1310
2	96,21%	97,11%	0,0796
3	97,17%	97,61%	0,0644
4	97,69%	97,89%	0,0586
5	97,94%	97,93%	0,0558
6	98,13%	98,30%	0,0487
7	98,29%	98,26%	0,0477
8	98,44%	98,75%	0,0373
9	98,57%	98,45%	0,0409
10	98,62%	98,66%	0,0384
11	98,80%	98,65%	0,0416
12	98,76%	98,57%	0,0403
13	98,85%	98,72%	0,0379
14	98,88%	98,65%	0,0389
15	98,90%	98,78%	0,0379

Bobot yang disimpan sebagai model terbaik berasal dari epoch ke-8, karena validation loss pada epoch tersebut paling kecil dan tidak terlampaui oleh epoch-epoch berikutnya. Selisih accuracy training dan validation pada akhir training kecil, yaitu sekitar 0,12 poin persentase, sehingga belum terlihat tanda overfitting yang jelas. Perubahan accuracy sepanjang epoch ditunjukkan pada Gambar 9.1, sedangkan perubahan loss ditunjukkan pada Gambar 9.2.



Gambar 9.1 Perbandingan Accuracy Training dan Validation pada Epoch Terpilih (Diolah dari Tabel 9.1)

Pada Gambar 9.2, training loss dan validation loss menurun secara signifikan, terutama pada epoch awal. Validation loss terendah tercapai pada epoch ke-8 sebesar 0,0373, sehingga bobot pada epoch tersebut disimpan sebagai model terbaik. Setelahnya, training loss terus menurun, sementara validation loss sedikit berfluktuasi. Secara keseluruhan, model menunjukkan proses pembelajaran yang baik tanpa indikasi overfitting yang kuat.



Gambar 9.2 Perbandingan Loss Training dan Validation pada Epoch Terpilih (Diolah dari Tabel 9.1)

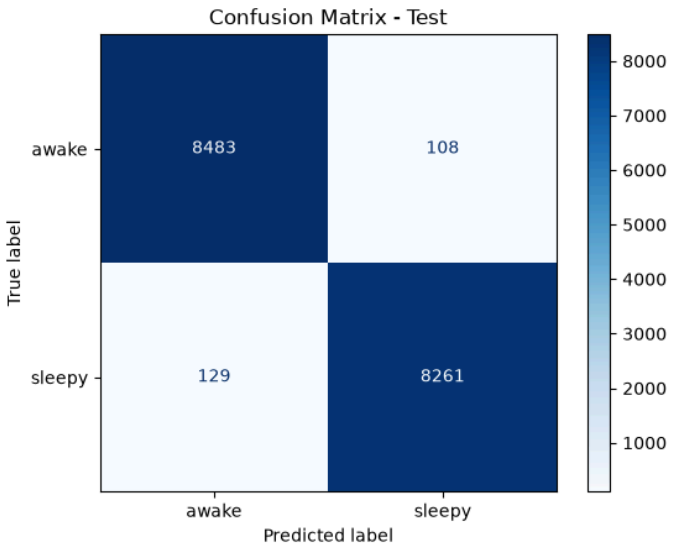
9.2 Hasil Pengujian Model pada Data Test

Setelah training, bobot terbaik dimuat kembali dan dievaluasi pada data test sebanyak 16.981 gambar, yang tidak dipakai selama training maupun pemilihan model. Hasilnya ditunjukkan pada confusion matrix di Gambar 9.3 dan Tabel 9.2. Dari 8.591 gambar awake, 8.483 diprediksi benar dan 108 salah dibaca sebagai sleepy. Dari 8.390 gambar sleepy, 8.261 diprediksi benar dan 129 salah dibaca sebagai awake. Secara keseluruhan, 16.744 gambar diprediksi benar dan 237 gambar salah, sehingga accuracy pada data test adalah 98,60%

Tabel 9.2 Confusion matrix pada data test

Kondisi Sebenarnya	Prediksi Awake	Prediksi Sleepy	Total
Awake	8.483	108	8.591
Sleepy	129	8.261	8.390

Dari confusion matrix tersebut, precision, recall, dan F1-score tiap kelas dapat dihitung seperti pada Tabel 9.3. Semua nilainya berada di kisaran 98,5% sampai 98,7%. Recall kelas sleepy sebesar 98,46% sedikit lebih rendah daripada recall kelas awake sebesar 98,74%, artinya sebagian kecil gambar mata tertutup terbaca sebagai terbuka.



Gambar 9.3 Confusion matrix pada test set, sesuai nilai Tabel 9.2

Tabel 9.3 Precision, recall, dan F1-score pada data test

Kelas	Precision	Recall	F1-Score	Jumlah Gambar
Awake	98,50%	98,74%	98,62%	8.591

Sleepy	98,71%	98,46%	98,59%	8.390

Selain pengujian pada data test, model juga dicoba pada satu gambar. Gambar pertama pada data test, yaitu gambar mata terbuka dari subjek s0001, diprediksi sebagai awake dengan skor 99,57%. Uji ini memastikan bahwa file model yang tersimpan dapat dimuat kembali dan dipakai untuk prediksi.

9.3 Pembahasan Hasil Aplikasi

Sistem juga dicoba langsung dengan webcam oleh anggota kelompok pada prototipe desktop OpenCV. Ketika mata ditutup selama sekitar 2 detik, peringatan visual muncul dan alarm berbunyi. Sistem tetap dapat bekerja pada pengguna yang memakai kacamata bening, tetapi tidak dapat bekerja pada pengguna yang memakai kacamata hitam, karena kacamata hitam menghalangi pandangan kamera ke mata. Hasil pengujian webcam yang lebih rinci ditunjukkan pada Tabel 8.1, sedangkan keterbatasannya dibahas pada Bab X.

Pada data test, model mencapai accuracy 98,60%, dengan 16.744 gambar diprediksi benar dan 237 gambar salah (Tabel 9.2 dan Tabel 9.3). Dua jenis kesalahan yang terjadi memiliki arti yang berbeda bagi sistem. Sebanyak 129 gambar mata tertutup terbaca sebagai terbuka (1,54% dari kelas sleepy), yang berarti recall kelas sleepy sebesar 98,46%. Kesalahan jenis ini dapat membuat durasi mata tertutup tidak terhitung. Sebanyak 108 gambar mata terbuka terbaca sebagai tertutup (1,26% dari kelas awake), yang dapat memicu peringatan yang sebenarnya tidak perlu. Karena sistem memakai penghalusan skor dan dua ambang, kesalahan pada satu gambar tidak otomatis mengubah status mata atau membunyikan alarm. Namun, seberapa besar pengaruh kesalahan ini pada sistem secara keseluruhan belum diukur dalam pengujian ini.

Hasil pengujian dengan webcam ditunjukkan pada Tabel 8.1. Ketika mata ditutup selama sekitar 2 detik, peringatan visual muncul dan alarm berbunyi. Sistem juga tetap bekerja pada pengguna yang memakai kacamata bening, tetapi tidak dapat bekerja pada pengguna yang memakai kacamata hitam.

Secara keseluruhan, hasil pada data test menunjukkan bahwa CNN mampu membedakan mata terbuka dan tertutup dengan baik pada gambar dari dataset, sedangkan pengujian webcam menunjukkan bahwa alur sistem dari deteksi sampai alarm dapat berjalan pada kondisi yang diuji. Meski begitu, pengujian webcam masih terbatas dan belum menghasilkan ukuran akurasi, sehingga performa sistem di luar kondisi yang diuji belum dapat dipastikan.

Hasil pengujian data test sebesar 98,60% menunjukkan kemampuan klasifikasi pada pembagian dataset yang tersedia. Keberhasilan demonstrasi desktop memperlihatkan integrasi kamera–CNN–timer–alarm dapat bekerja pada skenario awal. Berdasarkan implementasi kode, alur inferensi yang sama diterapkan dalam aplikasi berbasis browser setelah migrasi ke Gradio, tetapi pengujian kuantitatif terhadap antarmuka Gradio final belum terdokumentasi. Dengan demikian, akurasi test tidak disamakan dengan akurasi pemantauan pengguna real-time.

BAB X
KETERBATASAN DAN KENDALA

10.1 Keterbatasan Dataset dan Generalisasi

Kemungkinan kebocoran data antar subjek. Dataset berasal dari 37 subjek, dan pembagian data tidak dijelaskan oleh pengunggah di Kaggle. Jumlah gambar pada pembagian data hampir tepat 60%, 20%, dan 20% di kedua kelas, dan jumlah gambar awake pada validation dan test sama persis, yaitu 8.591. Pola ini menunjukkan kemungkinan pembagian dilakukan secara acak per gambar, bukan per subjek. Jika benar, orang yang sama dapat muncul pada data train dan data test, sehingga accuracy 98,60% bisa lebih tinggi daripada performa pada orang yang benar-benar baru. Pemeriksaan identitas subjek antar bagian dataset belum dilakukan secara terpisah. Karena itu, accuracy pada data test dibaca sebagai gambaran awal, dan pengujian webcam dengan orang baru menjadi pelengkap yang penting.

Perbedaan citra inframerah dan webcam. Model dilatih dengan gambar inframerah dari MRL Eye Dataset, sedangkan webcam laptop menangkap citra berwarna. Meskipun keduanya diproses menjadi grayscale, kualitas pencahayaan, kontras, dan noise tetap berbeda, sehingga accuracy test pada dataset belum tentu menggambarkan performa aktual aplikasi desktop.

Kacamata hitam belum didukung. Saat kacamata hitam digunakan, area mata tidak terlihat jelas oleh kamera sehingga prediksi tidak dapat diandalkan. Tampilan atau status terperinci ketika kondisi ini terjadi perlu didokumentasikan pada uji lanjutan.

10.2 Keterbatasan Deteksi dan Logika Peringatan

Alarm berhenti saat wajah tidak terdeteksi. Jika wajah atau salah satu mata tidak terdeteksi, timer direset dan alarm dihentikan. Akibatnya, jika pengguna menunduk atau wajahnya keluar dari frame saat mata tertutup, alarm tidak berbunyi. Padahal, kondisi itu bisa saja merupakan tanda kantuk yang lebih berat. Perilaku ini adalah keputusan rancangan yang sederhana, tetapi menjadi kekurangan untuk penggunaan yang sebenarnya.

Keterlambatan akibat penghalusan skor. Perubahan status memakai rata-rata bergerak berbobot 0,25 serta ambang 0,60 dan 0,40. Pendekatan ini membantu mengurangi perubahan status yang terlalu cepat, tetapi deteksi awal mata tertutup bisa tertunda beberapa frame. Besarnya keterlambatan saat memakai webcam desktop belum diukur secara sistematis.

Dua mata dirata-rata. Skor kelas sleepy dari kedua mata dirata-rata sebelum dibandingkan dengan ambang. Jika hanya satu mata yang tertutup, rata-rata skor berada di sekitar 0,5, yang di bawah ambang 0,60, sehingga status tidak berubah menjadi tertutup. Kondisi ini dianggap wajar untuk deteksi kantuk, tetapi berarti kedipan satu mata tidak akan terdeteksi.

10.3 Kendala Audio dan Browser

Berbeda dari aplikasi desktop yang menggunakan Pygame, versi Gradio memutar alarm melalui komponen audio pada browser. Proses inferensi dan pembaruan antarmuka dilakukan secara berulang selama webcam aktif, sehingga berpotensi menimbulkan jeda dalam pemantauan real-time. Namun, besarnya latency belum diukur secara kuantitatif. Oleh karena itu, pengujian lebih lanjut diperlukan untuk mengevaluasi ketepatan timer, kelancaran alarm, dan responsivitas antarmuka Gradio.

10.4 Cakupan Pengujian

Keterbatasan pengujian dan cakupan sistem. Pengujian webcam sejauh ini masih bersifat kualitatif dan jumlah uji coba belum terdokumentasi lengkap, sehingga belum ada estimasi akurasi seluruh sistem di kondisi real-case. Model hanya memantau mata tertutup dan belum menilai tanda lain seperti menguap atau kepala terkulai. Karena itu, peringatan yang dihasilkan hanya menunjukkan indikasi penutupan mata berkepanjangan, bukan diagnosis kantuk.

BAB XI
KESIMPULAN DAN RENCANA PENGEMBANGAN

11.1 Kesimpulan

DrowseGuard telah menghasilkan model EyeCNN untuk klasifikasi kondisi mata terbuka dan tertutup menggunakan MRL Eye Dataset. Hasil evaluasi pada 16.981 citra test menunjukkan accuracy sebesar 98,60%, dengan 16.744 gambar terklasifikasi benar dan 237 salah. Checkpoint terpilih berasal dari epoch ke-8 berdasarkan validation loss minimum sebesar 0,0373. Data tersebut menggambarkan performa model pada test set, bukan akurasi deteksi kantuk ketika digunakan melalui webcam.

Model kemudian diintegrasikan dengan MediaPipe Face Mesh, preprocessing konsisten, rata-rata skor dua mata, EMA, dan timer penutupan minimal 2 detik. Prototipe desktop telah menunjukkan fungsi peringatan visual serta audio pada sejumlah pengujian kualitatif. Pada implementasi akhir, antarmuka dikembangkan menjadi dashboard Gradio yang menerima webcam langsung dari browser, menampilkan kondisi mata dan preview, serta mengelola audio melalui komponen browser. Aplikasi merupakan prototipe indikasi penutupan mata berkepanjangan, bukan perangkat diagnosis kantuk atau jaminan keselamatan.

11.2 Rencana Pengembangan Lanjutan

Pengembangan berikutnya dibagi menjadi tiga tahap. Tahap pertama adalah pengujian dan pengukuran pada aplikasi Gradio, yaitu pengujian terstruktur dengan lebih banyak subjek, variasi pencahayaan, posisi kepala, dan kacamata, serta pengukuran latency, tingkat keberhasilan alarm, dan akurasi end-to-end. Tahap kedua adalah perbaikan model dan data, yaitu pemeriksaan kemungkinan tumpang tindih subjek pada pembagian dataset, lalu bila diperlukan, pemakaian data webcam nyata untuk penyesuaian model dengan tetap menjaga pemisahan data training dan pengujian yang jelas. Tahap ketiga adalah penyempurnaan sistem, yaitu pengujian penanganan wajah tidak terdeteksi, optimasi kelancaran streaming, dan penambahan indikator kantuk lain seperti menguap.

REFERENSI

akashshingha850. (n.d.). MRL Eye Dataset [Data set]. Kaggle. https://www.kaggle.com/datasets/akashshingha850/mrl-eye-dataset

Bisnis.com. (2024, 11 April). Supir kelelahan jadi biang kerok 2 kecelakaan maut saat mudik, Kemenhub peringati pengusaha bus. https://ekonomi.bisnis.com/read/20240411/98/1756930/supir-kelelahan-jadi-biang-kerok-2-kecelakaan-maut-saat-mudik-kemenhub-peringati-pengusaha-bus

Bradski, G. (2000). The OpenCV library. Dr. Dobb's Journal of Software Tools.

Brilian, A. P. (2023, 27 Maret). Kecelakaan lalin kerap terjadi saat mudik, begini tips menghindarinya. detikFinance. https://finance.detik.com/berita-ekonomi-bisnis/d-6639167/kecelakaan-lalin-kerap-terjadi-saat-mudik-begini-tips-menghindarinya

Fusek, R. (2018). Pupil localization using geodesic distance. International Symposium on Visual Computing (ISVC). Dataset tersedia di https://mrl.cs.vsb.cz/eyedataset.html

Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. Nature, 585(7825), 357-362.

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. Computing in Science & Engineering, 9(3), 90-95.

Kartynnik, Y., Ablavatski, A., Grishchenko, I., & Grundmann, M. (2019). Real-time facial surface geometry from monocular video on mobile GPUs. CVPR Workshop on Computer Vision for Augmented and Virtual Reality. arXiv:1907.06724.

Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. 3rd International Conference on Learning Representations (ICLR). arXiv:1412.6980.

LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. Nature, 521(7553), 436-444.

LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11), 2278-2324.

Lugaresi, C., Tang, J., Nash, H., et al. (2019). MediaPipe: A framework for building perception pipelines. arXiv:1906.08172.

Paszke, A., Gross, S., Massa, F., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. Advances in Neural Information Processing Systems, 32.

Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.

Soukupová, T., & Čech, J. (2016). Real-time eye blink detection using facial landmarks. 21st Computer Vision Winter Workshop, Rimske Toplice, Slovenia.

TorchVision maintainers & contributors. (2016). TorchVision: PyTorch's computer vision library [Computer software]. https://github.com/pytorch/vision

Gradio. (n.d.). Gradio documentation [Computer software documentation]. https://www.gradio.app/docs

LAMPIRAN

Appendix A: Pernyataan Orisinalitas dan Kontribusi

Kami menyatakan bahwa proyek ini merupakan hasil pengerjaan kelompok dengan mencantumkan sumber eksternal yang digunakan. Pembagian tugas dan kontribusi setiap anggota telah disusun berdasarkan tanggung jawab serta pekerjaan yang benar-benar dilakukan selama pengerjaan proyek. Setiap anggota bertanggung jawab atas kontribusinya masing-masing dalam penyelesaian proyek ini.

Appendix B: GitHub / Version Control Statement

a. **Platform Version Control:** GitHub
b. **Tautan Repository:** https://github.com/fuhrerhn/drowsiness-detection
c. **Pernyataan Penggunaan:**

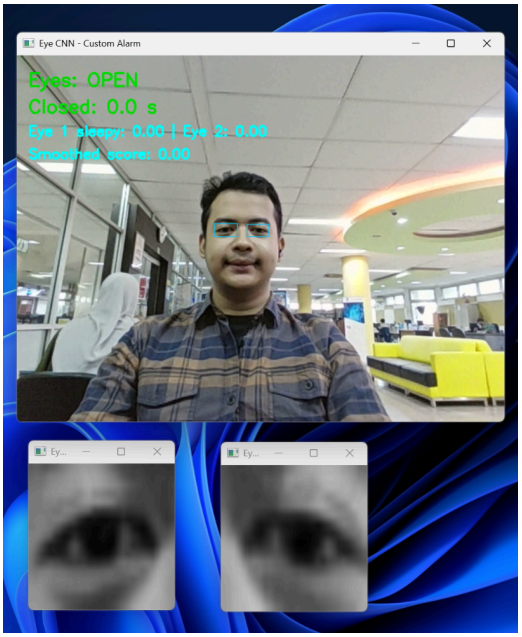
Kelompok menggunakan GitHub sebagai sarana version control untuk menyimpan dan mengelola kode proyek. Platform ini membantu kelompok dalam melacak perubahan kode, mengintegrasikan hasil pekerjaan setiap anggota, serta menjaga riwayat pengembangan proyek.

Appendix C: Dokumentasi Prototipe Desktop (Tahap Progress)

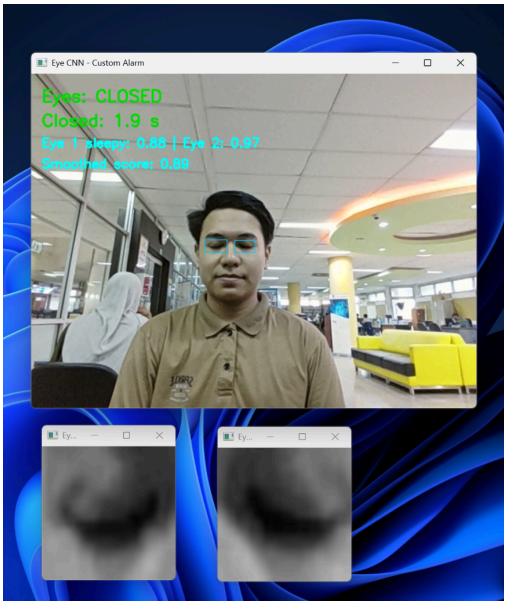
Sebelum beralih ke Gradio, sistem diuji melalui jendela OpenCV desktop. Gambar di bawah merupakan dokumentasi historis tahap progress; hasil dan antarmuka ini tidak dinyatakan sebagai hasil pengujian Gradio final.



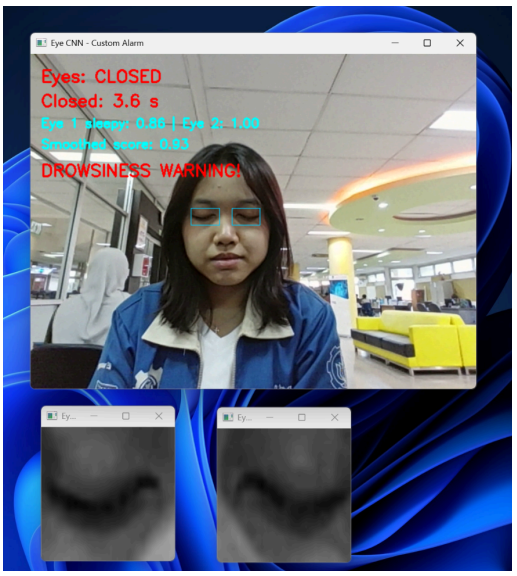
Gambar L.1: Jendela desktop OpenCV dan preview mata pada webcam pada tahap progress



Gambar L.2 Mata terbuka: status OPEN dan timer 0 detik pada tahap progress



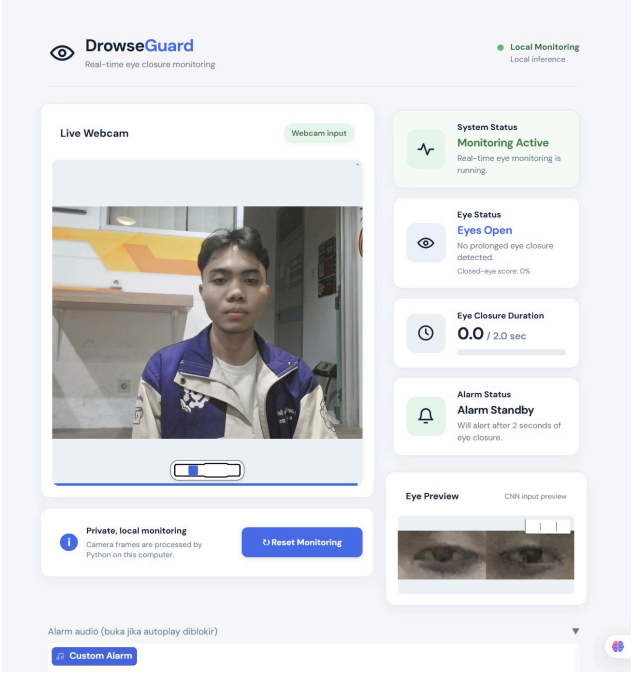
Gambar L.3 Mata tertutup sebelum batas 2 detik: timer berjalan pada tahap progress



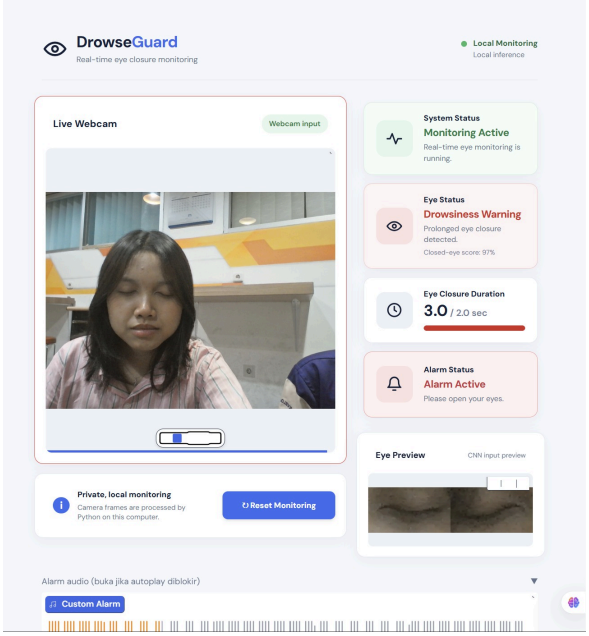
Gambar L.4 Mata tertutup minimal 2 detik: DROWSINESS WARNING! dan alarm aktif pada tahap progress

Appendix D: Dokumentasi Prototipe Desktop (Tahap Final)

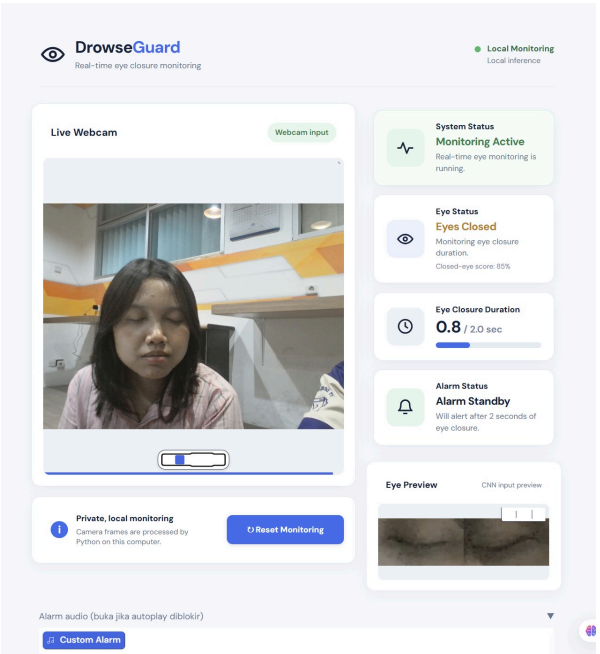
Pada tahap final, sistem dikembangkan menggunakan antarmuka berbasis Gradio untuk memberikan pengalaman pemantauan yang lebih interaktif melalui browser. Gambar di bawah menunjukkan tampilan akhir aplikasi beserta fitur utama yang telah diimplementasikan, meliputi pemantauan webcam secara real-time, status mata, durasi penutupan mata, pratinjau mata, serta peringatan visual dan audio ketika mata tertutup selama minimal 2 detik.



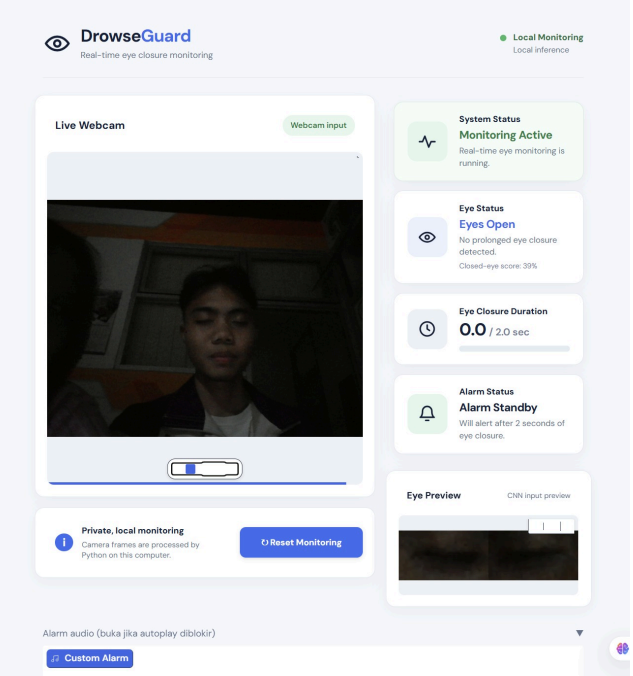
Gambar L.5 Mata terbuka dengan status Eyes Open pada tahap final



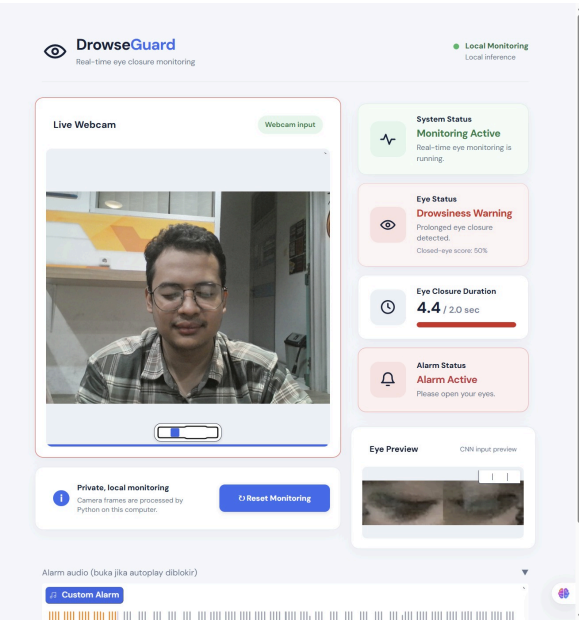
Gambar L.6 Mata tertutup minimal 2 detik: DROWSINESS WARNING! dan alarm aktif pada tahap final



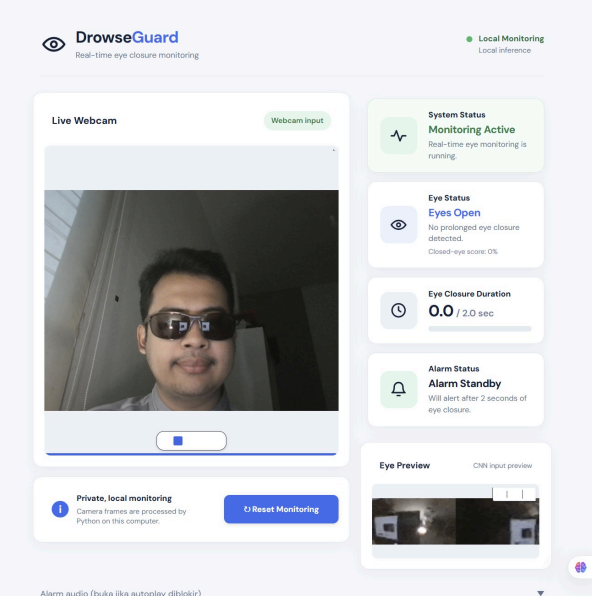
Gambar L.7 Mata tertutup dengan durasi di bawah 2 detik pada tahap final



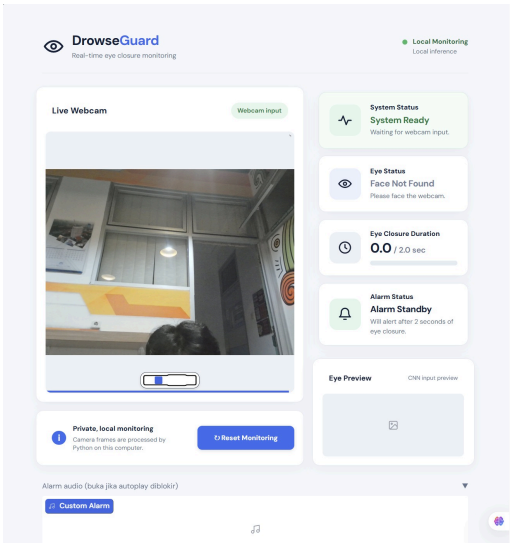
Gambar L.8 Mata tertutup pada pencahayaan redup dan sistem tidak dapat mendeteksi mata pada tahap final



Gambar L.9 Mata tertutup dengan penggunaan kacamata bening pada tahap final



Gambar L.10 Mata tertutup dengan penggunaan kacamata hitam pada tahap final



Gambar L.11 Wajah atau mata tidak terdeteksi di kamera pada tahap final